Motivation et formalisation

Introduction au Machine Learning

Théo Lopes Quintas

BPCE Payment Services,
Université Paris Dauphine

2022-2026

Motivation

Trois orientations

Nous ne pouvons qu'avoir un aperçu du futur, mais cela suffit pour comprendre qu'il y a beaucoup à faire.
— Alan Turing (1950)

Je dirais que l'on n'apprend que dans les cours où l'on travaille sur des problèmes. Il est essentiel que les étudiants tentent de résoudre des problèmes. [...] Se borner à écouter ne sert pas à grand chose.
— Werner Heisenberg (1963)

La logique ne fait que sanctionner les conquêtes de l'intuition.
— Jacques Hadamard (1972)

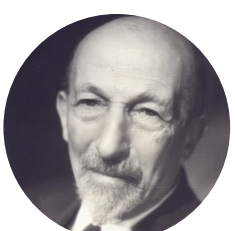

Les différentes approches du Machine Learning

Supervisé ou non-supervisé

Nous travaillerons dans ce cours sur deux approches possible en Machine Learning : l'apprentissage **supervisé** et l'apprentissage **non-supervisé**.

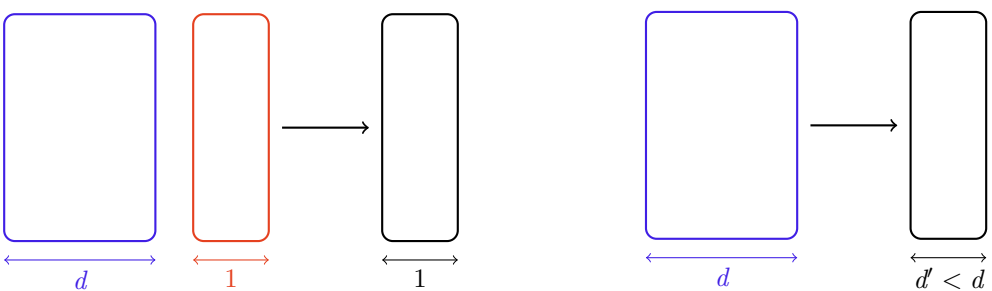

(a) Supervisé **(b)** Non-supervisé

Figure – Deux types d'apprentissage schématisé

Les deux cas nécessite des **données** et le supervisé a besoin également d'une **cible**. C'est sur ce dernier que porte la première partie du cours.

Apprentissage supervisé

Dataset

Le Machine Learning supervisé nécessite des **informations** (notées X ou x) pour prédire une **cible** (notée Y ou y).

$$\mathcal{D} = \left\{ (x^{(i)}, y_i) \mid \forall i \leqslant \underbrace{n}_{\text{Nombre d'observations}},\ x^{(i)} \in \mathbb{R}^{\overbrace{d}^{\text{Nombre d'informations}}},\ y_i \in \mathcal{Y} \right\} \tag{1}$$

L'hypothèse du datascientist est qu'il existe une certaine fonction f, inconnue a priori, qui fait le lien entre les observations $x \in \mathbb{R}^d$ et la réponse y.

$$\exists f : \mathbb{R}^d \to \mathcal{Y},\ \forall i \leqslant n,\ y_i = f\left(x^{(i)}\right) + \varepsilon_i \ \text{ avec } \varepsilon_i \text{ le bruit}$$

Apprentissage supervisé

Fonction de perte et fonction de coût

Exercice 1

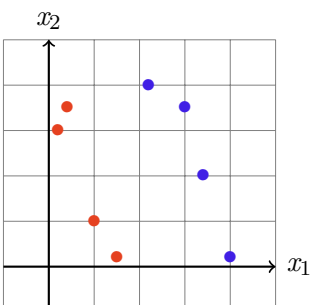

Trouver la meilleure fonction f_θ qui renvoie 0 pour les ronds bleus et 1 pour les ronds rouges parmi les propositions suivantes avec

$\mathcal{L}(\theta; x, y) = \mathbb{1}_{y \neq f_\theta(x_1, x_2)}$ *donc* $\mathcal{C}(\theta; X, y) = \sum_{i=1}^{n} \mathcal{L}(\theta, x, y)$.

1. $f_\theta(x_1, x_2) = \mathbb{1}_{x_1 \leqslant \theta}$
2. $f_\theta(x_1, x_2) = \mathbb{1}_{x_2 \leqslant \theta}$

A partir du dataset et de notre hypothèse, on défini deux fonctions :

- La **fonction de perte** $\mathcal{L} : \mathbb{R}^{d'} \times \mathbb{R}^d \times \mathbb{R}$
- La **fonction de coût** $\mathcal{C} : \mathbb{R}^{d'} \times \mathcal{M}_{n,d} \times \mathbb{R}^n$

La majorité du temps la fonction de coût correspond à la somme des fonctions de perte pour chaque observations.

Sélection de modèle

Train, Validation, Test

A partir du dataset d'entraînement on peut former un jeu de **Train** et un de **Validation**. Le premier sert à apprendre les paramètres des différents modèles que l'on souhaite tester, le second sert à mesurer la performance pour trouver le *meilleur*.
Puis on peut exploiter le modèle gagnant sur le jeu de **Test**.

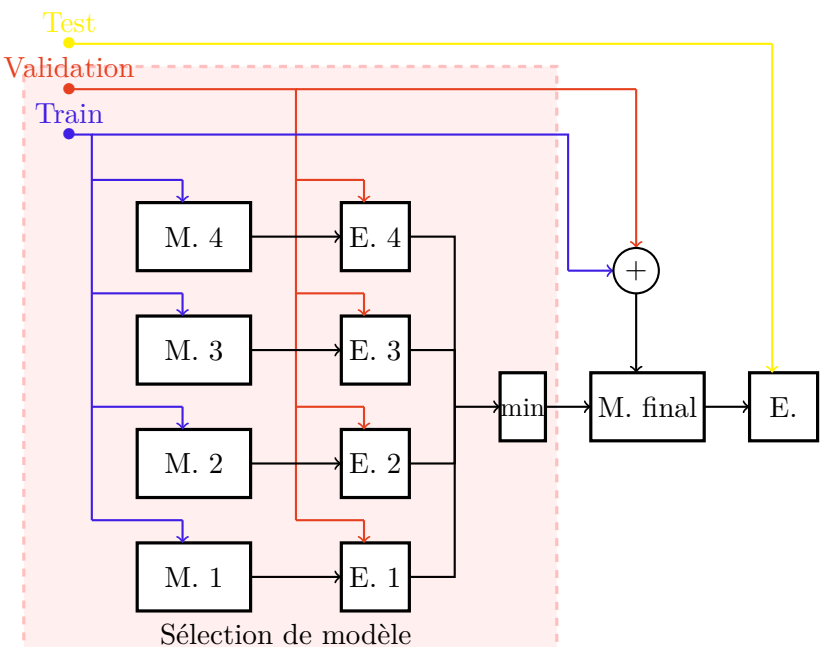

Sélection de modèle

Validation croisée

Plutôt que d'avoir une unique valeur de performance, on peut en obtenir plusieurs en réalisant une **validation croisée**. Il faut garder en tête que puisque le dataset est découpé en plusieurs pli aléatoirement, **il ne doit pas être dépendant du temps**.

Figure – Schéma d'une validation croisée